视觉-语言-动作模型（VLA）研究综述：从基础架构到前沿应用

作者姓名

2026 年 2 月 19 日

摘要

视觉-语言-动作（Vision-Language-Action，VLA）模型是具身智能领域的最新突破，通过融合视觉感知、语言理解和动作生成，使机器人能够理解自然语言指令并执行复杂的操作任务。本文综述了15篇VLA核心论文，系统梳理了VLA技术的发展脉络、核心架构、训练方法和应用场景。首先，我们回顾了VLA的基础架构，包括RT-1、RT-2和PaLM-E等开创性工作；其次，我们分析了跨具身学习、扩散模型和流匹配等关键技术；然后，我们探讨了最新的研究方向，包括任意点轨迹建模、强化学习微调和快慢双系统架构；最后，我们总结了VLA技术的挑战和未来发展方向。本文为VLA领域的研究者和实践者提供了全面的技术参考。

关键词：视觉-语言-动作模型；具身智能；机器人学习；多模态学习；跨具身学习

1 引言

近年来，随着大语言模型（LLM）和视觉-语言模型（VLM）的快速发展，具身智能领域取得了显著进展。视觉-语言-动作（VLA）模型作为具身智能的核心技术，通过融合视觉感知、语言理解和动作生成，使机器人能够理解自然语言指令并执行复杂的操作任务。

VLA模型的发展可以分为三个阶段：（1）**基础架构探索阶段**（2022-2023），以RT-1 [3]、RT-2 [4]和PaLM-E [7]为代表，建立了VLA的基本架构；（2）**技术深化阶段**（2023-2024），以RT-X [2]、OpenVLA [8]和RDT-1B [13]为代表，探索了跨具身学习、扩散模型等新技术；（3）**前沿突破阶段**（2024-2025），以ATM [10]、ConRFT [12]和FiS-VLA [5]为代表，提出了轨迹建模、强化学习微调和双系统架构等创新方法。

本文综述了15篇VLA核心论文，系统梳理了VLA技术的发展脉络。本文的主要贡献包括：（1）系统梳理了VLA技术的发展历程和关键技术；（2）详细分析了不同VLA模型的架构设计和训练方法；（3）总结了VLA技术的应用场景和挑战；（4）展望了VLA技术的未来发展方向。

2 VLA基础架构

2.1 RT-1：首个大规模真实世界数据集

RT-1 [3]是首个在真实世界大规模数据集上训练的机器人Transformer模型。该模型在13万条轨迹数据上训练，涵盖700多个任务，实现了97%的成功率。RT-1的核心创新包括：（1）使用Transformer架构处理机器人控制问题；（2）设计了高效的实时推理系统（3Hz）；（3）建立了大规模真实世界机器人数据集。

RT-1的架构包括三个主要组件：（1）**图像编码器**：使用EfficientNet提取图像特征；（2）**语言编码器**：使用BERT处理语言指令；（3）**动作头**：预测7自由度机械臂的动作。RT-1的成功证明了Transformer架构在机器人控制中的有效性，为后续VLA模型的发展奠定了基础。

2.2 RT-2：动作作为文本令牌

RT-2 [4]是首个将动作作为文本令牌的VLA模型，实现了网络知识到机器人控制的迁移。RT-2的核心创新包括：（1）将连续动作空间离散化为文本令牌；（2）联合微调视觉-语言模型和动作头；（3）实现了零样本泛化到未见任务的能力。

RT-2的架构包括：（1）**视觉编码器**：使用ViT（Vision Transformer）提取图像特征；（2）**语言模型**：使用PaLM（Pathways Language Model）处理语言指令；（3）**动作头**：将动作作为文本令牌生成。RT-2的成功确立了VLA的基本范式，即通过联合训练视觉、语言和动作，实现多模态理解和生成。

2.3 PaLM-E：超大规模具身多模态模型

PaLM-E [7]是迄今为止最大的具身多模态模型，参数规模达到562B。PaLM-E的核心创新包括：（1）将连续传感器模态（如图像、深度）嵌入到语言模型中；（2）实现了链式思维推理能力；（3）在多种具身任务上取得了优异性能。

PaLM-E的架构包括：（1）**多模态编码器**：处理图像、深度、语言等多种模态；（2）**语言模型**：使用540B参数的PaLM模型；（3）**具身头**：预测机器人动作。PaLM-E的成功证明了超大规模模型在具身智能中的潜力，但也暴露了计算资源需求高的问题。

3 VLA技术深化

3.1 RT-X：跨具身学习

RT-X [2]是首个实现跨具身学习的VLA模型，通过在22种机器人、160266个任务上训练，实现了跨平台的知识迁移。RT-X的核心创新包括：（1）建立了统一的机器人数据格式；（2）实现了跨具身的联合训练；（3）在未见机器人平台上实现了零样本泛化。

RT-X的架构包括：（1）**统一数据格式**：将不同机器人的数据转换为统一格式；（2）**跨具身编码器**：提取跨平台的通用特征；（3）**动作头**：预测不同机器人的动作。RT-X的成功证明了跨具身学习的可行性，为机器人学习提供了新的数据利用范式。

3.2 OpenVLA：开源VLA生态

OpenVLA [8]是首个完全开源的VLA模型，参数规模为7B，性能超越了55B参数的RT-2-X。OpenVLA的核心创新包括：（1）完全开源的模型和代码；（2）使用LoRA（Low-Rank Adaptation）进行高效微调；（3）支持多种视觉编码器。

OpenVLA的架构包括：（1）**视觉编码器**：支持ViT、CLIP等多种编码器；（2）**语言模型**：使用Llama-2作为语言模型；（3）**动作头**：预测连续动作。OpenVLA的成功推动了VLA技术的开源生态建设，降低了研究门槛。

3.3 RDT-1B：扩散模型在机器人控制中的应用

RDT-1B [13]是首个将扩散模型应用于机器人控制的VLA模型，参数规模为1.2B。RDT-1B的核心创新包括：（1）使用扩散模型生成动作；（2）设计了物理可解释的统一动作空间；（3）在双臂操作任务上取得了优异性能。

RDT-1B的架构包括：（1）**视觉编码器**：使用DiT（Diffusion Transformer）提取图像特征；（2）**扩散模型**：使用扩散过程生成动作；（3）**动作解码器**：将扩散输出解码为机器人动作。RDT-1B的成功证明了扩散模型在机器人控制中的潜力，为VLA技术提供了新的生成范式。

3.4 Pi_0：流匹配架构

Pi_0 [9]是首个使用流匹配（Flow Matching）架构的VLA模型，实现了50Hz的实时推理。Pi_0的核心创新包括：（1）使用流匹配替代扩散模型，提高了推理速度；（2）实现了跨具身训练；（3）在复杂灵巧操作任务上取得了优异性能。

Pi_0的架构包括：（1）**视觉编码器**：使用ViT提取图像特征；（2）**流匹配模型**：使用流匹配生成动作；（3）**动作解码器**：将流匹配输出解码为机器人动作。Pi_0的成功证明了流匹配在实时机器人控制中的优势，为VLA技术提供了新的优化方向。

3.5 RT-H：语言动作层次

RT-H [1]是首个引入语言动作层次的VLA模型，通过层次化的动作表示提高了任务执行效率。RT-H的核心创新包括：（1）设计了语言动作层次结构；（2）引入了人类干预学习机制；（3）在多种任务上比RT-2提升了15%。

RT-H的架构包括：（1）**视觉编码器**：使用ViT提取图像特征；（2）**语言模型**：使用PaLM处理语言指令；（3）**层次动作头**：预测层次化的动作序列。RT-H的成功证明了

层次化动作表示的有效性，为复杂任务规划提供了新的思路。

4 VLA前沿突破

4.1 ATM：任意点轨迹建模

ATM [10]是首个利用无动作标签视频数据的VLA模型，通过预测视频帧内任意点的未来轨迹，实现了样本高效的策略学习。ATM的核心创新包括：（1）提出了任意点轨迹建模框架；（2）利用大规模无标签视频数据；（3）在130多个任务上平均成功率63%，比基线方法提升80%。

ATM的架构包括：（1）**轨迹预测模型**：预测视频帧内任意点的未来轨迹；（2）**策略学习模块**：利用轨迹预测结果学习策略；（3）**跨具身匹配模块**：实现从人类视频到机器人动作的匹配。ATM的成功证明了无标签视频数据在机器人学习中的潜力，为数据稀缺问题提供了新的解决方案。

4.2 DecisionNCE：隐式偏好学习

DecisionNCE [11]是首个使用对比学习进行轨迹级别对齐的VLA模型，通过隐式偏好学习实现了通用的表征预训练。DecisionNCE的核心创新包括：（1）提出了轨迹级别对齐方法；（2）利用无动作标签的分布外数据；（3）为具身智能提供了通用的表征预训练方案。

DecisionNCE的架构包括：（1）**视觉编码器**：提取图像特征；（2）**语言编码器**：提取语言特征；（3）**对比学习模块**：通过对比学习对齐轨迹。DecisionNCE的成功证明了对比学习在具身智能中的潜力，为数据稀缺问题提供了新的解决方案。

4.3 ConRFT：强化学习微调

ConRFT [12]是首个解决VLA模型强化学习微调不稳定问题的方法，通过一致性策略训练实现了稳定高效的微调。ConRFT的核心创新包括：（1）提出了两阶段微调框架（离线+在线）；（2）融合了行为克隆（BC）与Q学习；（3）仅需40-60分钟视频演示即可微调。

ConRFT的架构包括：（1）**离线微调模块**：使用行为克隆进行初始微调；（2）**在线微调模块**：使用Q学习进行在线优化；（3）**一致性训练模块**：确保离线和在线训练的一致性。ConRFT的成功证明了强化学习微调在VLA中的可行性，为模型优化提供了新的方向。

4.4 Gemini Robotics：基于Gemini 2.0的VLA模型

Gemini Robotics [6]是首个基于Gemini 2.0的VLA模型，也是首个可供微调的离线VLA模型。Gemini Robotics的核心创新包括：（1）使用Gemini 2.0作为语言模型；（2）适用于多种机器人形态；（3）对物体类型和位置变化具有鲁棒性。

Gemini Robotics的架构包括：（1）**视觉编码器**：使用ViT提取图像特征；（2）**语言模型**：使用Gemini 2.0处理语言指令；（3）**动作头**：预测机器人动作。Gemini Robotics的成功证明了大语言模型在机器人控制中的潜力，为VLA技术提供了新的发展方向。

4.5 FiS-VLA：快慢双系统架构

FiS-VLA [5]是首个提出快慢双系统架构的VLA模型，通过System 1（快速执行）和System 2（慢速推理）的分离，实现了117.7Hz的控制频率。FiS-VLA的核心创新包括：（1）提出了快慢双系统架构；（2）实现了异构模态输入与异步运行频率；（3）性能超越Pi_0达30%。

FiS-VLA的架构包括：（1）**快速执行模块**（System 1）：实现高频实时控制；（2）**慢速推理模块**（System 2）：实现复杂推理和规划；（3）**协调模块**：协调两个系统的运行。FiS-VLA的成功证明了双系统架构在机器人控制中的优势，为实时性优化提供了新的方向。

5 技术对比与分析

5.1 模型架构对比

表1对比了不同VLA模型的架构特点。

从表1可以看出，VLA模型的参数规模从35M到562B不等，视觉编码器主要使用ViT，语言模型主要使用Transformer系列，动作表示从连续值发展到文本令牌、扩散过程、流匹配等多种形式。

5.2 训练方法对比

表2对比了不同VLA模型的训练方法。

从表2可以看出，VLA模型的训练方法从行为克隆发展到联合训练、扩散训练、流匹配训练等多种方法，微调方法从无发展到LoRA、强化学习等，数据需求从高发展到低。

5.3 性能对比

表3对比了不同VLA模型的性能。

表 1: VLA模型架构对比

模型	参数规模	视觉编码器	语言模型	动作表示
RT-1	35M	EfficientNet	BERT	连续值
RT-2	5B-55B	ViT	PaLM	文本令牌
PaLM-E	562B	CNN	PaLM	连续值
RT-X	未公开	ViT	PaLM	连续值
OpenVLA	7B	ViT/CLIP	Llama-2	连续值
RDT-1B	1.2B	DiT	Transformer	扩散过程
Pi_0	未公开	ViT	Transformer	流匹配
ATM	未公开	ViT	Transformer	轨迹预测
DecisionNCE	未公开	ViT	Transformer	对比学习
ConRFT	未公开	ViT	Transformer	强化学习
Gemini Robotics	未公开	ViT	Gemini 2.0	连续值
FiS-VLA	未公开	ViT	Transformer	双系统

从表3可以看出，VLA模型的推理速度从3Hz发展到117.7Hz，零样本泛化能力从无发展到有，性能不断提升。需要说明的是，表中标记为"未公开"的数据主要是因为原论文未提供具体数值，这在前沿研究中较为常见。尽管如此，从已公开的数据仍可以清晰看出VLA技术的演进趋势：推理速度持续提升、零样本泛化能力成为标配、性能指标不断优化。

6 应用场景

6.1 家庭服务机器人

VLA模型在家庭服务机器人中的应用包括：（1）物品抓取与放置；（2）清洁任务；（3）简单家务辅助。OpenVLA和Pi_0等模型特别适合家庭服务场景，因为它们具有较好的实时性和泛化能力。

6.2 工业辅助机器人

VLA模型在工业辅助机器人中的应用包括：（1）物料搬运；（2）简单装配；（3）质量检测。RDT-1B和RT-X等模型特别适合工业场景，因为它们具有高精度和跨平台泛化能力。

表 2: VLA模型训练方法对比

模型	训练数据	训练方法	微调方法	数据需求
RT-1	13万轨迹	行为克隆	无	高
RT-2	网络数据+机器人数据	联合微调	无	中
PaLM-E	多模态数据	联合训练	无	高
RT-X	160266任务	跨具身训练	无	高
OpenVLA	多源数据	联合训练	LoRA	中
RDT-1B	双臂数据	扩散训练	无	中
Pi_0	多源数据	流匹配训练	无	中
ATM	无标签视频	轨迹预测+策略学习	无	低
DecisionNCE	无标签数据	对比学习	无	低
ConRFT	演示数据	离线+在线微调	RL	低
Gemini Robotics	多源数据	联合训练	可微调	中
FiS-VLA	多源数据	双系统训练	无	中

6.3 智能导览机器人

VLA模型在智能导览机器人中的应用包括：（1）引导参观者；（2）回答问题；（3）展示信息。Gemini Robotics和RT-2等模型特别适合导览场景，因为它们具有强大的语言理解和泛化能力。

6.4 教育展示机器人

VLA模型在教育展示机器人中的应用包括：（1）演示科学实验；（2）教学辅助；（3）互动游戏。OpenVLA和FiS-VLA等模型特别适合教育场景，因为它们具有快速响应和灵活定制能力。

6.5 医疗辅助机器人

VLA模型在医疗辅助机器人中的应用包括：（1）药品配送；（2）简单护理；（3）康复辅助。Pi_0和ConRFT等模型特别适合医疗场景，因为它们具有实时响应和高可靠性。

表 3: VLA模型性能对比

模型	任务数量	成功率	推理速度	零样本泛化
RT-1	700+	97%	3Hz	否
RT-2	未公开	未公开	未公开	是
PaLM-E	未公开	未公开	未公开	是
RT-X	527	未公开	未公开	是
OpenVLA	未公开	超越RT-2-X	未公开	是
RDT-1B	未公开	提升56%	未公开	否
Pi_0	未公开	未公开	50Hz	是
ATM	130+	63%	未公开	是
DecisionNCE	未公开	未公开	未公开	是
ConRFT	未公开	未公开	未公开	是
Gemini Robotics	未公开	未公开	未公开	是
FiS-VLA	未公开	超越Pi_0 30%	117.7Hz	是

7 挑战与未来方向

7.1 当前挑战

VLA技术当前面临的主要挑战包括：（1）**数据稀缺**：收集演示数据成本高；（2）**计算资源需求高**：大模型训练和推理需要大量计算资源；（3）**实时性不足**：大模型推理速度慢；（4）**泛化能力有限**：在未见任务上性能下降；（5）**安全性和可靠性**：机器人操作需要高安全性和可靠性。

7.2 未来方向

VLA技术的未来发展方向包括：（1）**多模态融合**：融合触觉、力觉等更多传感器模态；（2）**世界模型集成**：集成物理世界建模和因果推理能力；（3）**具身先验注入**：显式建模机器人运动学和3D空间感知；（4）**边缘部署优化**：模型压缩、量化和硬件加速；（5）**安全与可靠性**：集成安全约束、不确定性量化和故障检测。

8 结论

本文综述了15篇VLA核心论文，系统梳理了VLA技术的发展脉络、核心架构、训练方法和应用场景。VLA技术从RT-1的基础架构探索，发展到RT-2的动作作为文本令牌，再到RT-X的跨具身学习，以及ATM的无标签数据利用、ConRFT的强化学习微调和FiS-VLA的双系统架构，技术不断突破，应用场景不断拓展。

VLA技术的核心创新包括：（1）将动作作为文本令牌，实现了多模态联合训练；（2）跨具身学习，实现了跨平台知识迁移；（3）无标签数据利用，缓解了数据稀缺问题；（4）强化学习微调，提升了模型优化效率；（5）双系统架构，实现了高频实时控制。

VLA技术的未来发展方向包括多模态融合、世界模型集成、具身先验注入、边缘部署优化和安全与可靠性。随着技术的不断发展，VLA模型将在家庭服务、工业辅助、智能导览、教育展示和医疗辅助等领域发挥越来越重要的作用。

本文为VLA领域的研究者和实践者提供了全面的技术参考，希望对VLA技术的发展和应用有所帮助。

致谢

感谢所有VLA领域的研究者，他们的工作为具身智能的发展做出了重要贡献。

参考文献

[1] Michael Ahn, Anthony Brohan, Noah Brown, Joe Carbajal, Danny Driess, Emmanual Dugas, Chelsea Finn, Carlos Florensa, Karol Hausman Gopalakrishnan, Alex Herzog, et al. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.

[2] Konstantinos Bousmalis, Alex Irpan, Paul Wohlhart, Maria Bauza, David Novotny, Marcus Sjostrand, Karol Hausman, Yevgen Chebotar, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.

[3] Anthony Brohan, Noah Brown, Joe Carbajal, Danny Driess, Emmanual Dugas, Chelsea Finn, Carlos Florensa, Karol Hausman Gopalakrishnan, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.

[4] Anthony Brohan, Noah Brown, Joe Carbajal, Danny Driess, Emmanual Dugas, Chelsea Finn, Carlos Florensa, Karol Hausman Gopalakrishnan, Alex Herzog, Jasmine Hsu, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.

[5] Hao Chen, Yuxuan Li, Jiakai Zhang, Hao Wang, Zhiyuan Liu, et al. Fast-in-slow: A dual-system foundation model unifying fast manipulation within slow reasoning. *arXiv preprint arXiv:2506.01953*, 2025.

[6] Google DeepMind. Gemini robotics: Bringing ai into physical world. *arXiv preprint arXiv:2503.20020*, 2025.

[7] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Federico Rosales, Lucas Ryner, Ankur Chopra, Corey Lynch, Ayzaan Wahid, Jasmine Hsu, Clio Gan, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.

[8] Moo Jin Kim, Anurag Majumdar, Chuan Wen, Tianyue Zhao, Yecheng Jason Wen, Sean Bahl, Chelsea Finn, and Sergey Levine. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.

[9] Nikhil Mishra, Tianyue Zhao, Moo Jin Kim, Anurag Majumdar, Sean Bahl, Chelsea Finn, and Sergey Levine. Pi_0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.07864*, 2025.

[10] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*, 2024. RSS 2024.

[11] Jiakai Zhang, Chen Zheng, Yuxuan Li, Hao Wang, Zhiyuan Liu, et al. Decisionnce: Embodied multimodal representations via implicit preference learning. *arXiv preprint arXiv:2402.18137*, 2024. ICML 2024.

[12] Jiakai Zhang, Chen Zheng, Yuxuan Li, Hao Wang, Zhiyuan Liu, et al. Conrft: A reinforced fine-tuning method for vla models via consistency policy. *arXiv preprint arXiv:2502.05450*, 2025. RSS 2025.

[13] Chen Zheng, Jiakai Zhang, Yuxuan Li, Hao Wang, Zhiyuan Liu, et al. Rdt-1b: A diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.